Michał Zagajewski
Oliwier Polak
Uniwersytet Jagielloński w Krakowie
2026 / 2027

Zaawansowane koło olimpijskie

Olimpiada AI

Format zawodów, terminy, najważniejsze informacje

Etap	Kiedy?	Gdzie?
I Etap	1.12.2026 – 25.01.2027	Zdalnie
II Etap	5 – 7.03.2027	Kraków, Poznań, Warszawa, Wrocław
Finał	23 – 26.04.2027	Kraków

oai.edu.pl

Jak będą wyglądać zajęcia?

01 Walidacja i klasyczne ML

02 Gradient Descent i optymalizacja

03 Transformery i language modeling

04 NLP i fine-tuning

05 Embeddings i retrieval

06 Klasyfikacja wieloetykietowa

07 Object detection

08 Segmentacja obrazów

09 Modele generatywne

10 Audio i modele pretrained

11 Anomaly detection i OOD

12 Adversarial attacks i probing

AI na naszych zajęciach

AI może pomagać, ale nie rozwiązuje zadania za Ciebie.

Qwen3-8B - lokalnie - *ollama.com/download*

```
macOS / Linux: curl -fsSL https://ollama.com/install.sh | sh
Windows: irm https://ollama.com/install.ps1 | iex
```

```
ollama pull qwen3:8b
ollama run qwen3:8b --think=false (/set nothink)
```

01

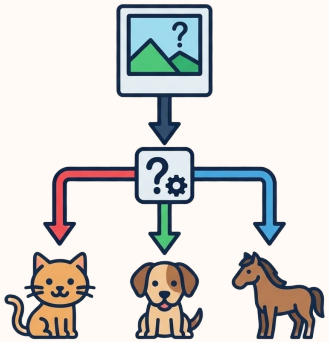
Walidacja i klasyczne ML

Rodzaje problemów

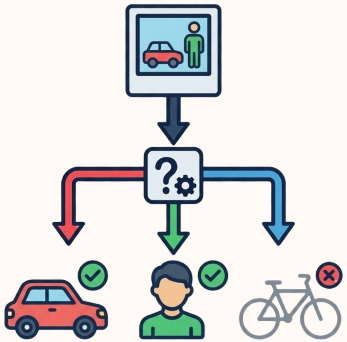
Klasyfikacja Binarna



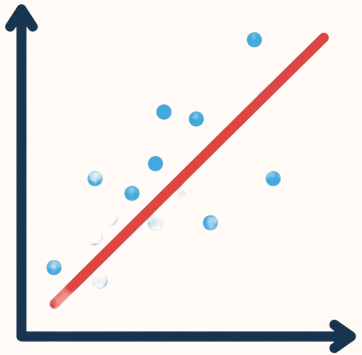
Klasyfikacja wieloklasowa



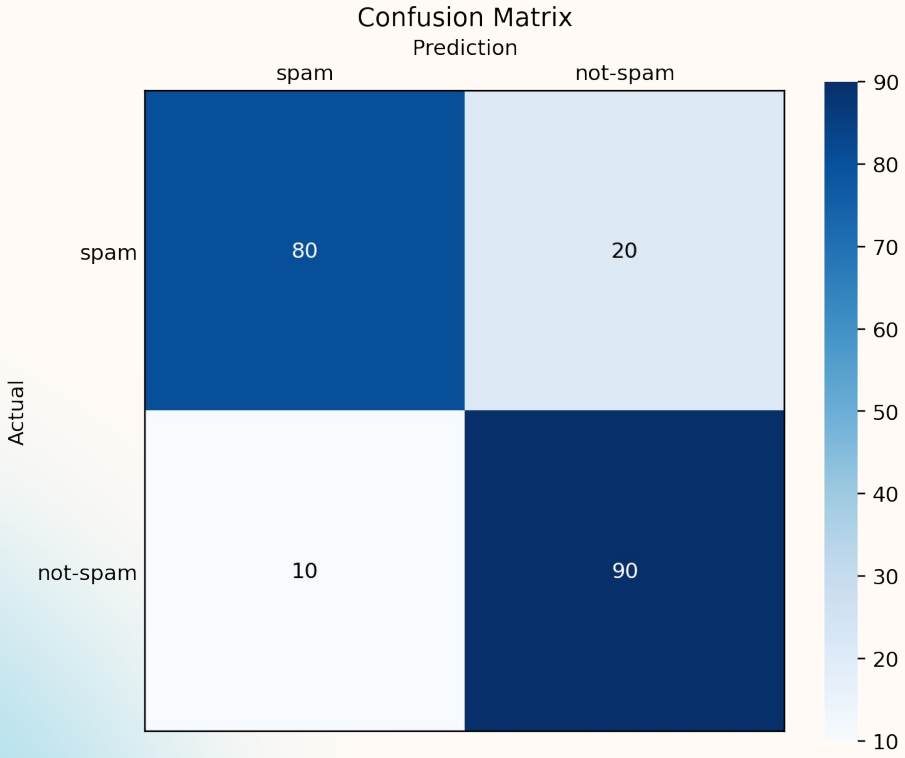
Klasyfikacja wieloetykietowa



Regresja



Od predykcji do metryki



$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN} = 0.85$$

$$Precision = \frac{TP}{TP + FP} \approx 0.89$$

$$Recall = \frac{TP}{TP + FN} = 0.80$$

$$Specificity = \frac{TN}{TN + FP} = 0.90$$

$$F1 = 2 \cdot \frac{Precision \cdot Recall}{Precision + Recall} \approx 0.84$$

Metryki dla wielu klas

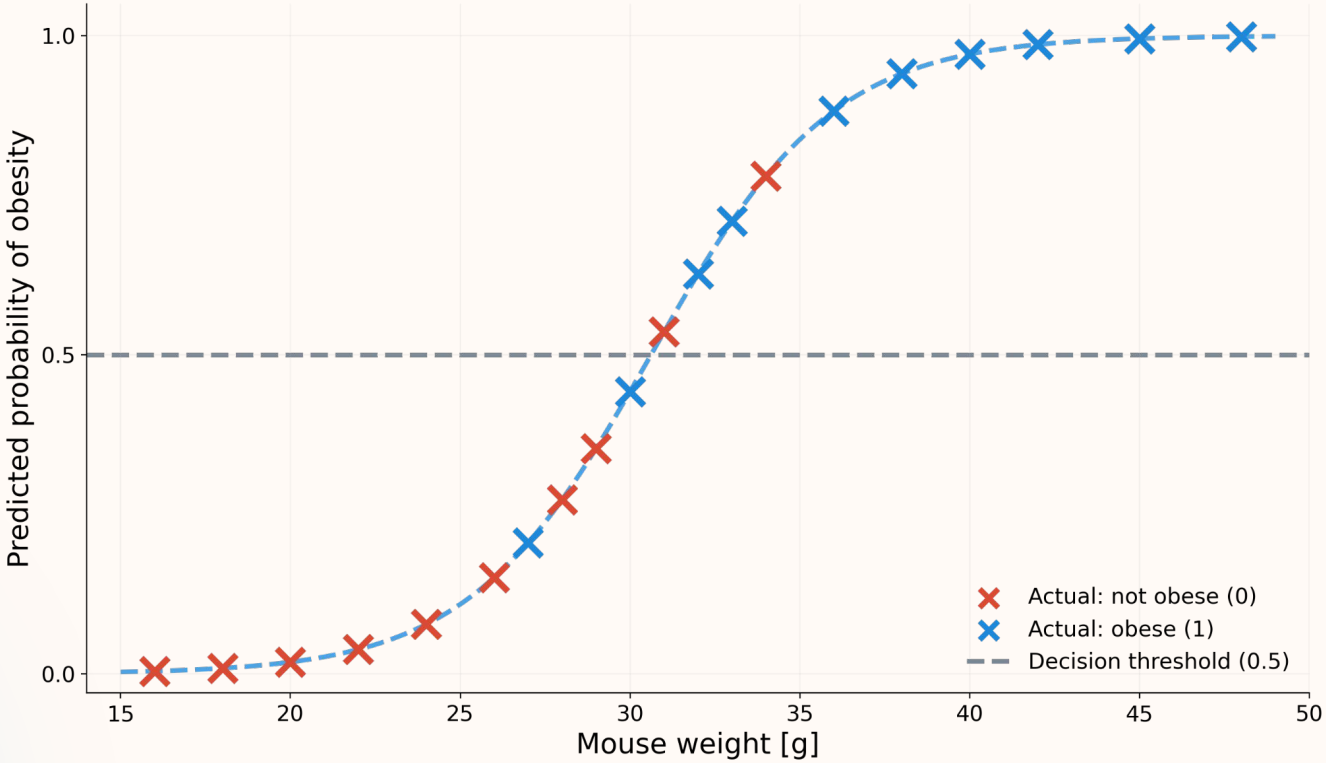
Klasa	Precision	Recall	F1-score	Support
✈️ Samolot	0.67	0.67	0.67	3
🚢 Statek	0.25	1.00	0.40	1
🚗 Samochód	1.00	0.50	0.67	6

$$\text{Macro F1} = \frac{1}{N}\sum_{i=1}^{N} \text{F1}_i \approx 0.58$$

$$\text{Weighted F1} = \frac{\sum_{i=1}^{N} S_i \cdot \text{F1}_i}{\sum_{i=1}^{N} S_i} \approx 0.64$$

$$\text{Micro F1} = \frac{\sum_{i=1}^{N} \text{TP}_i}{\sum_{i=1}^{N} S_i} = 0.60$$

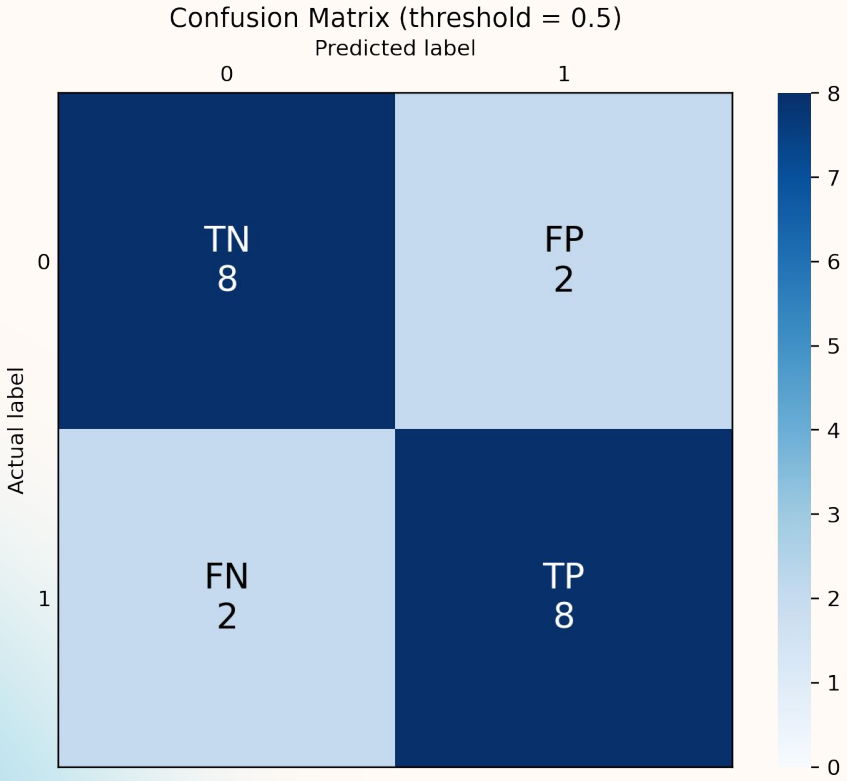
ROC-AUC

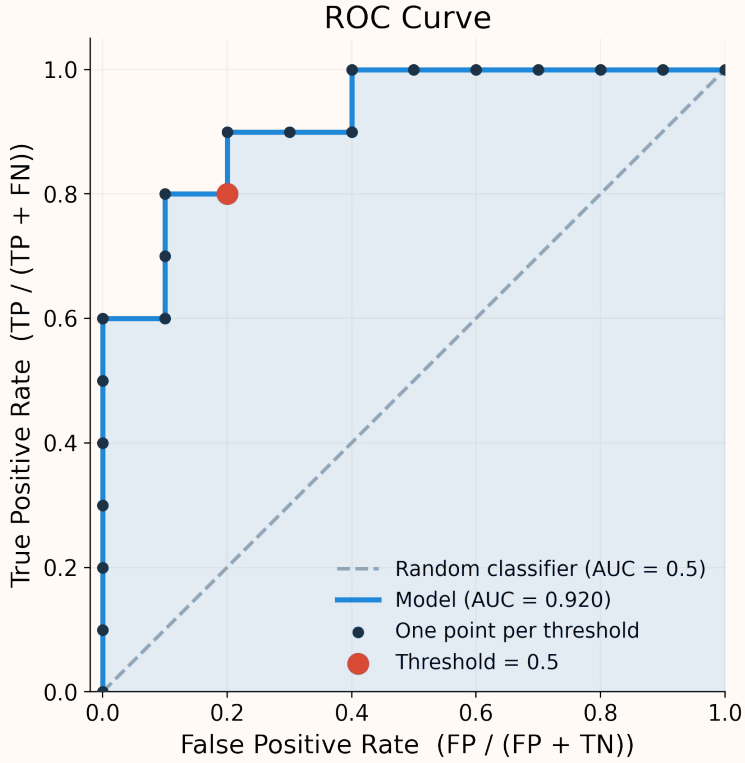

1.0
0.5
0.0
Predicted probability of obesity
15
20
25
30
35
40
45
50
Mouse weight [g]
Actual: not obese (0)
Actual: obese (1)
Decision threshold (0.5)

ROC-AUC

$$TPR = \frac{TP}{TP + FN} = \frac{8}{8 + 2} = 0.8$$

$$FPR = \frac{FP}{FP + TN} = \frac{2}{2 + 8} = 0.2$$





Train, validation i test



TRAIN

Uczymy model

Dopasowujemy parametry modelu do danych treningowych.

- Nie służy do wyboru modelu ani ustawień.

VALIDATION

Wybieramy rozwiązanie

Porównujemy modele, hiperparametry, preprocessing, threshold itd.

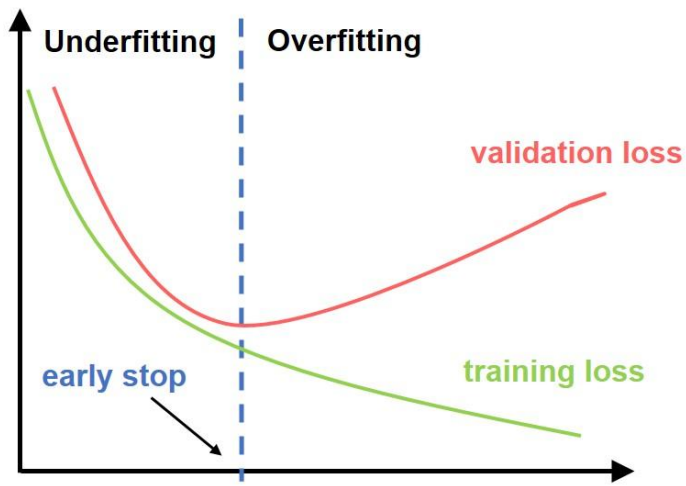
- Może być sprawdzany
- Powinien odzwierciedlać dane, na których model będzie używany.

TEST

Końcowa ocena

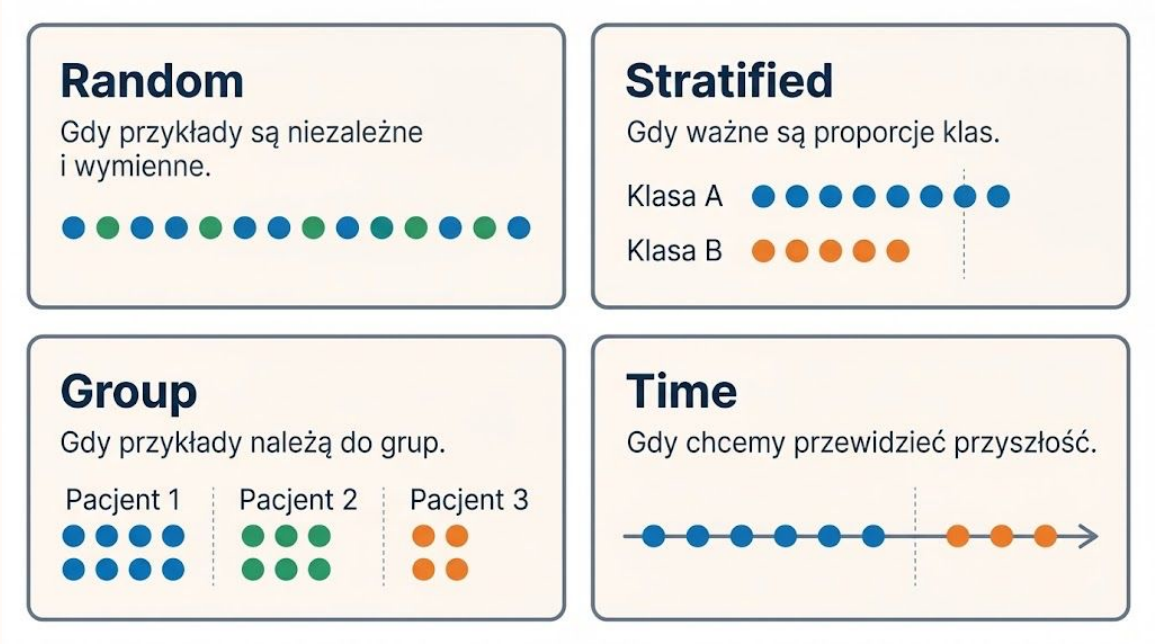
Daje niezależne oszacowanie jakości wybranego rozwiązania.

- Jego wynik nie może wpływać na decyzje projektowe.



Dzielenie i ocenianie danych

Strategia podziału zależy od tego, co ma symulować test. Warto sprawdzić stabilność wyniku.



Cross-validation

Powtarzamy ocenę na różnych podziałach danych.

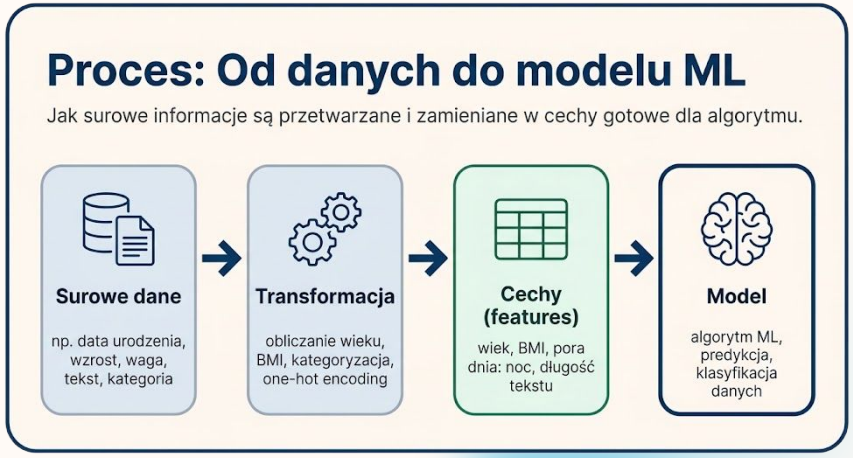
Fold	Wynik (accuracy)
1	0,84
2	0,87
3	0,81
4	0,85
5	0,86

średnia: 0.85 ± 0.02

Feature Engineering

Feature Engineering to projektowanie reprezentacji danych wejściowych tak, aby model mógł skuteczniej nauczyć się zależności istotnych dla zadania.

Źle wykonany Feature Engineering może powodować wyciek danych.



1 Przykłady transformacji

Z surowych danych tworzymy cechy, które lepiej oddają kontekst i zależności w danych.

Dane surowe		Cecha dla modelu
data urodzenia + data wizyty	→	wiek
wzrost + waga	→	BMI
godzina: 23:47	→	pora dnia: noc
tekst: „Kupiłem nowy..."	→	długość tekstu: 16
kategoria: „samochód"	→	one-hot encoding

Wyciek danych

Wyciek transformacji ⚠

Wykonywanie jakichkolwiek operacji na danych przy użyciu statystyk z całego zbioru (Train + Val + Test) przed jego podziałem.

Dotyczy to m.in.:

- Skalowania (obliczanie globalnej średniej/odchylenia dla **StandardScaler**)
- Imputacji braków (np. uzupełnianie medianą z całości)
- Redukcji wymiarowości (PCA)

Zbiór treningowy zyskuje w ten sposób nieuprawnioną wiedzę o globalnym rozkładzie, w tym o danych testowych.

Wyciek celu ⚠

Użycie jako cechy (feature) wejściowej zmiennej, która z natury jest skutkiem przewidywanego zdarzenia, a nie jego przyczyną, lub która w środowisku produkcyjnym pojawi się dopiero po fakcie.

Przykład:

- Przewidywanie, czy klient zrezygnuje z usługi (churn), gdzie jedną z cech wejściowych jest „data ostatniej rozmowy z działem utrzymania klienta".

W ten sposób model uczy się na „danych z przyszłości" – cechach, które podczas rzeczywistej prognozy nie będą jeszcze w ogóle istnieć.

Wyciek grupowy ⚠

Zastosowanie naiwnego, losowego podziału danych w sytuacji, gdy w zbiorze występują grupy silnie powiązanych rekordów.

Przykład: Podział danych pacjentów (np. po 10 zdjęć rentgenowskich na osobę). Zdjęcia tej samej osoby nie mogą trafić jednocześnie do obu zbiorów (treningowego i testowego).

Trafienie powiązanych danych do obu zbiorów sprawia, że model de facto rozpoznaje konkretną osobę (memorization), a nie obiektywne cechy patologii na zdjęciu.

Wyciek czasu ⚠

Ignorowanie naturalnej chronologii zdarzeń i stosowanie zwykłego podziału krzyżowego (Standard K-Fold) dla szeregów czasowych.

Skutek:

- Model uczy się na danych historycznych wymieszanych z „przyszłością" zamiast na konsekwentnym podziale chronologicznym.

Model trenuje wtedy na danych z „przyszłości", aby przewidzieć „przeszłość" – co jest wdrożeniowo całkowicie niemożliwe.

Wyciek przez duplikaty ⚠

Niesprawdzenie i nieusunięcie duplikatów ze zbioru przed jego podziałem.

Konsekwencja:

- Identyczne przykłady lądują zarówno w części treningowej, jak i testowej.

Sztucznie pompuje to metryki, ponieważ model ocenia de facto próbki treningowe (które zdążył już zapamiętać).

Wyciek meta-optymalizacyjny ⚠

Strojenie hiperparametrów i podejmowanie tysięcy decyzji projektowych na podstawie wyników ze zbioru walidacyjnego.

Problem:

- Inżynier nieświadomie staje się w tym procesie algorytmem ręcznie dopasowującym model do próby walidacyjnej.

W najbardziej skrajnej formie jest to podejmowanie decyzji o architekturze na podstawie wyników ze zbioru testowego.

Zadanie

Wykrywanie zaburzeń sygnału EKG

Link **GitHub OAI**
Link **Sprawdzai**

Dla chętnych

Save the Factory: Feature Engineering Challenge
IOAI 2024 ML Problem
Link **GitHub IOAI**