Michał Zagajewski
Oliwier Polak
Uniwersytet Jagielloński w Krakowie
2026 / 2027

Zaawansowane koło olimpijskie

Co dziś?

- Różniczkowalność i gradient
- Optymalizacja (GD, SGD, Momentum, RMSprop, Adam, AdamW)
- Backpropagation
- Zadanie

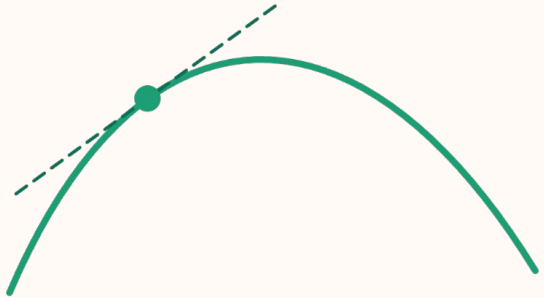
02

Gradient Descent i optymalizacja

Różniczkowalność

Różniczkowalna

gładko, bez załamań

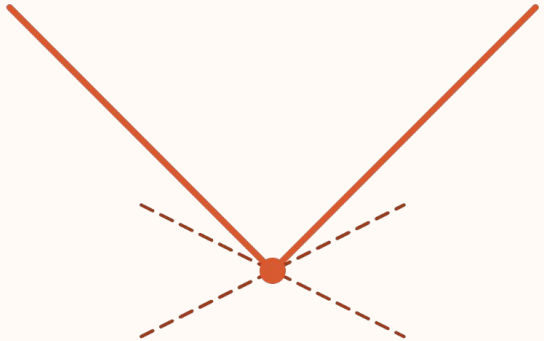


Jedna styczna, f′(a) istnieje

f′(a) = lim (f(a+h) − f(a)) / h

Nieróżniczkowalna

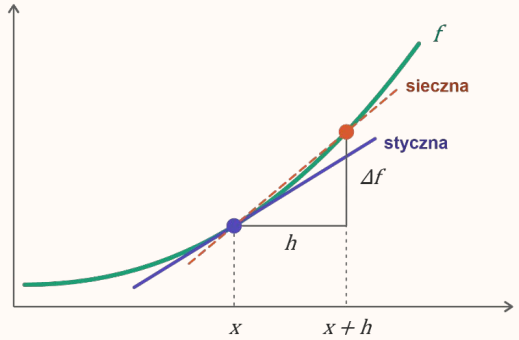
ostry kąt w jednym punkcie



Wiele stycznych, brak f′(0)

pochodna lewa ≠ prawa

Pochodna i gradient

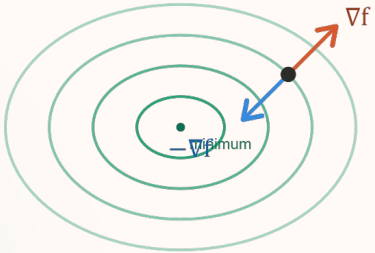


Pochodna

$$f'(x) = \lim_{h \to 0} \frac{f(x+h) - f(x)}{h}$$

Nachylenie stycznej do wykresu w punkcie x, czyli chwilowa szybkość zmiany funkcji.

Gdy h → 0, sieczna zamienia się w styczną.



poziomice funkcji $f(x_1, x_2)$

Gradient

$$\nabla f(x) = (\partial f/\partial x_1, \ldots, \partial f/\partial x_n)$$

Wektor pochodnych cząstkowych. Wskazuje kierunek najszybszego wzrostu funkcji.

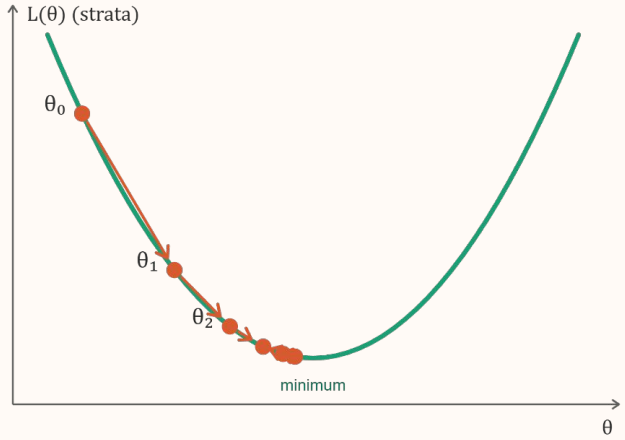
W uczeniu maszynowym idziemy w przeciwną stronę:

$$\theta \leftarrow \theta - \eta \nabla L(\theta)$$

η to krok uczenia (learning rate), L to funkcja straty

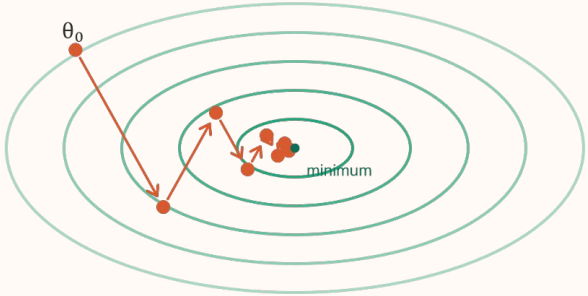
Gradient descent

W jednym wymiarze



Na początku: duży gradient, duży krok.
Blisko minimum: gradient ≈ 0, małe kroki.

W wielu wymiarach (poziomice)



Każdy krok idzie przeciwnie do gradientu,
a wydłużona dolina daje zygzak.

$$\theta_{t+1} = \theta_t - \eta \, \nabla L(\theta_t)$$

η (learning rate) to rozmiar kroku, L to funkcja straty.

Powtarzaj, aż gradient będzie bliski zeru.

Jak liczymy gradient?

Funkcja straty to średnia po paczce danych B: $\nabla L_B(\theta) = \frac{1}{|B|} \sum_{i \in B} \nabla \ell(x_i, y_i; \theta)$

Batch Gradient Descent
($|B| = N$, cały zbiór)

- Wylicza dokładny gradient po wszystkich przykładach treningowych.
- Zalety: Gładka, deterministyczna ścieżka prosto do minimum.
- Wady: Ogromny koszt pamięci (VRAM) i bardzo długi czas pojedynczego kroku.



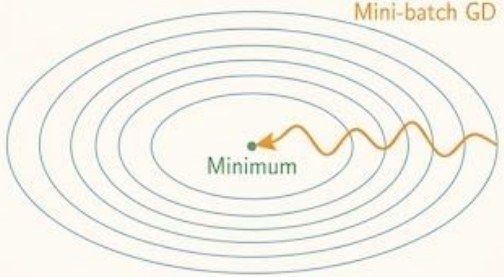
Stochastic Gradient Descent – SGD
($|B| = 1$, jedna próbka)

- Aktualizuje wagi po każdym pojedynczym przykładzie.
- Zalety: Błyskawiczne kroki; losowy szum pomaga wyskakiwać z płytkich minimów lokalnych.
- Wady: Duża wariancja – trajektoria mocno zygzakuje i oscyluje wokół minimum.



Mini-batch Gradient Descent
($|B| \in \{32, 64, 256\}$)

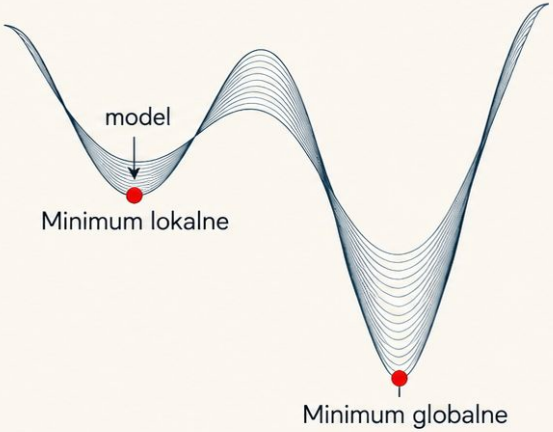
- Złoty środek w Deep Learningu: uśrednia gradient po małej paczce danych.
- Zalety: Redukuje szum względem czystego SGD i maksymalnie wykorzystuje równoległość macierzową na kartach GPU.
- Wady: Trzeba dobrać dodatkowy hiperparametr (rozmiar paczki $|B|$).



Pułapki i wyzwania

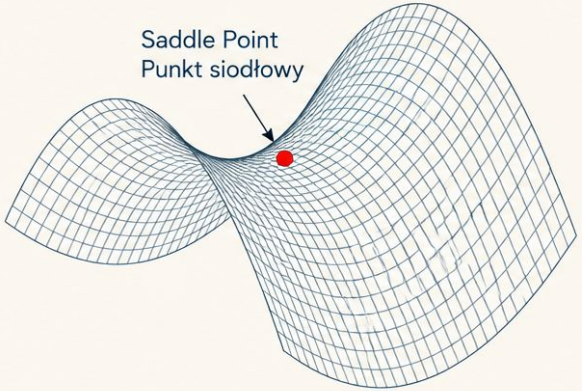
Minima: Lokalne vs Globalne

- **Cel:** Znalezienie minimum globalnego o najniższym błędzie w całej przestrzeni.
- **Problem:** Algorytm może utknąć w suboptymalnym minimum lokalnym, z którego każdy krok prowadzi w górę.



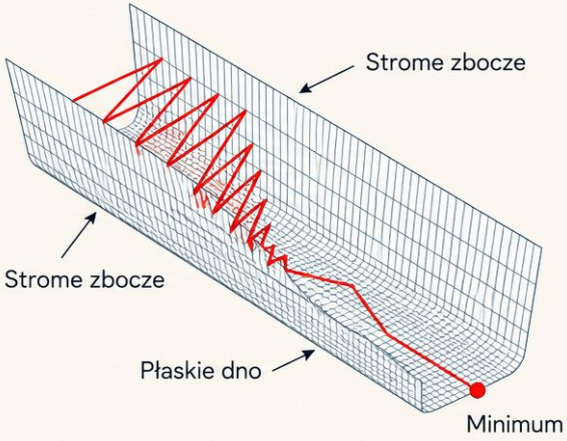
Punkty siodłowe

- **Definicja:** Punkt, w którym krzywizna jest wypukła w jednych kierunkach, a wklęsła w innych.
- **Konsekwencja:** Gradient znika, przez co model grzęźnie fra na płaskim obszarze, zamiast iść do minimum.



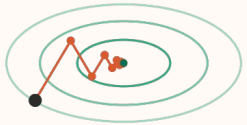
Nierówne skalowanie

- **Wygląd:** Funkcja ma postać wydłużonej, bardzo wąskiej doliny – wąwozu, gdzie jedna oś ma o wiele większy gradient niż druga.
- **Problem:** Algorytm gwałtownie zygzakuje między stromymi zboczami, zamiast iść wprost wzdłuż łagodnego dna w stronę minimum.



Inne optymalizatory

Gradient descent

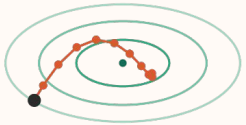


$$\theta \leftarrow \theta - \eta\, g$$

$g = \nabla L(\theta)$

Idzie wprost w dół zbocza. Prosty, ale zygzakuje w wąskich dolinach i bywa wolny.

Momentum

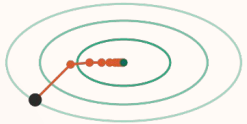


$$v \leftarrow \beta\, v + g$$

$$\theta \leftarrow \theta - \eta\, v$$

Pamięta poprzednie kierunki (jak kula z rozpędem): wygładza zygzak i przyspiesza w dobrym kierunku.

RMSProp

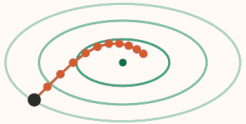


$$s \leftarrow \rho\, s + (1-\rho)\, g^2$$

$$\theta \leftarrow \theta - \eta\, g \,/\, (\sqrt{s} + \varepsilon)$$

Dzieli krok przez średnią kwadratów gradientów: każdy parametr dostaje własny, dopasowany krok.

Adam



$$m \leftarrow \beta_1\, m + (1-\beta_1)\, g$$

$$s \leftarrow \beta_2\, s + (1-\beta_2)\, g^2$$

$$\theta \leftarrow \theta - \eta\, \hat{m} \,/\, (\sqrt{\hat{s}} + \varepsilon)$$

Łączy momentum i RMSProp: pęd plus adaptacyjny krok. Najczęstszy domyślny wybór w deep learningu.

Ścieżki: 10 kroków z tego samego punktu startu (czarna kropka), zielona kropka to minimum.

Backpropagation

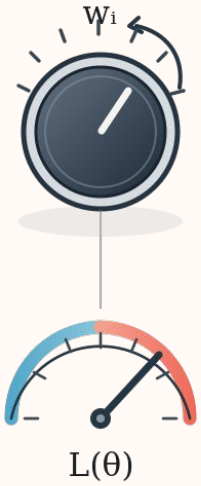
Co mówi gradient?

$$\frac{\partial L}{\partial w_i}$$

Pochodna mierzy lokalną wrażliwość straty na zmianę wagi.

Znak
kierunek zmiany straty przy wzroście wagi

Moduł
siła lokalnej reakcji straty



$$\theta_{t+1} = \theta_t - \eta \nabla \theta L$$

Parametry przesuwamy w kierunku przeciwnym do gradientu.

Jak obliczyć gradient?

Różnice skończone

$$\frac{\partial L}{\partial w_i} \approx \frac{L(\theta + \varepsilon e_i) - L(\theta)}{\varepsilon}$$

N parametrów → O(N) ewaluacji sieci.

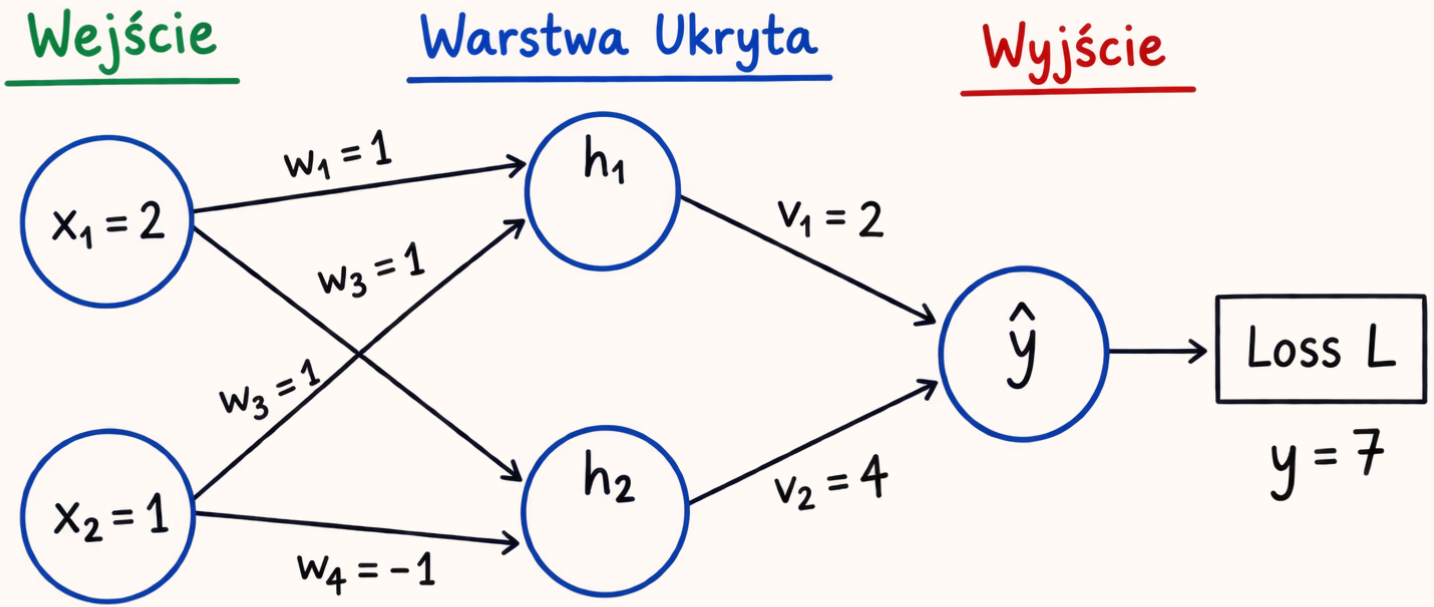
Backpropagation

Reguła łańcuchowa + ponowne wykorzystanie pochodnych pośrednich (δ).

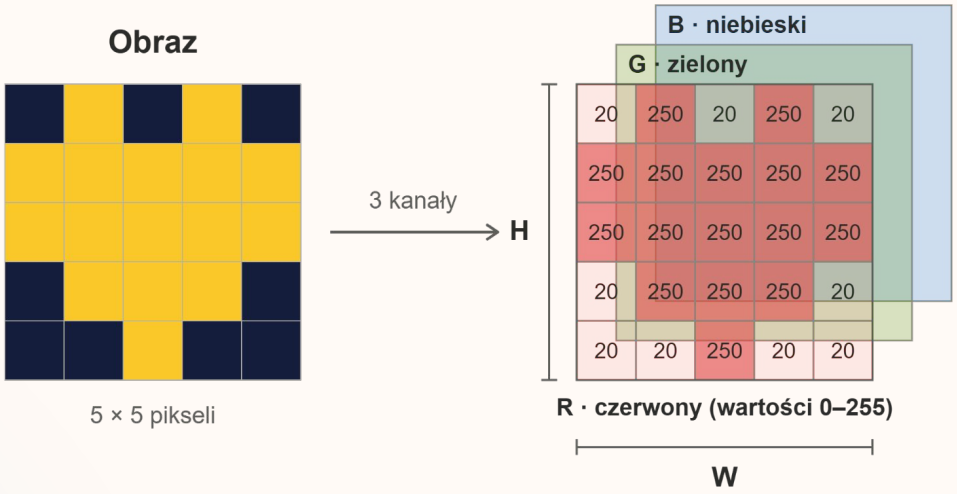
$$\frac{\partial L}{\partial W^{(l)}} = \delta^{(l)} \, (a^{(l-1)})^T$$

Jeden forward pass i jeden backward pass,
zamiast osobnego przeliczania sieci dla każdej wagi.

Backpropagation - przykład



Model obrazu



Obraz = tensor o kształcie (H, W, 3)

tutaj (5, 5, 3), czyli 5 × 5 × 3 = 75 liczb

Zadanie

Optymalizator Malarza

Link **GitHub OAI**
Link **SprawdzAi**